Distância até a faculdade e escolaridade: análise por regressão linear

Trabalho de Econometria Básica, 2026/2. Base: `CollegeDistance`, do pacote AER do R.

Integrantes: A preencher

Professor(a): A preencher

Instituição: A preencher

Turma: A preencher

1. Pergunta de pesquisa e base de dados

Pergunta: como a distância até a faculdade e as condições familiares se relacionam com os anos de escolaridade dos jovens?

Resposta resumida: na especificação principal, 10 milhas a mais até uma faculdade de quatro anos se associam a 0,024 ano a menos de escolaridade, cerca de 0,3 mês, comparando estudantes com os mesmos controles observados. A associação é estatisticamente distinta de zero a 5%, mas pequena. Renda, educação dos pais e desempenho inicial têm associações bem maiores. Os resultados não demonstram efeito causal.

A base é um corte transversal da pesquisa *High School and Beyond*, realizada em 1980 nos Estados Unidos, com acompanhamento em 1986. A pesquisa incluiu estudantes de cerca de 1.100 escolas de ensino médio. Cada linha representa um estudante. Os dados vêm do pacote AER (Kleiber; Zeileis, 2008), cuja documentação indica como fonte os complementos on-line de Stock e Watson (2007).

São 4.739 observações e 14 variáveis, sem valores ausentes e sem linhas repetidas. Nenhuma observação foi excluída ou imputada na especificação principal, e a análise não usa pesos amostrais.

2. Estatísticas descritivas, correlações e gráficos

Tabela 1. Estatísticas descritivas das variáveis numéricas do modelo.

Variável	Média	Mediana	Variância	Desvio padrão	Mínimo	Máximo
`education` (anos)	13,81	13,00	3,20	1,79	12,00	18,00
`distance` (dezenas de milhas)	1,80	1,00	5,28	2,30	0,00	20,00
`score` (pontos)	50,89	51,19	75,72	8,70	28,95	72,81

A escolaridade se concentra em 12 anos (38,7% da amostra) e 16 anos (19,1%). A distância tem cauda longa: metade dos estudantes está a até 10 milhas, o máximo é de 200 milhas, e 94 estudantes têm distância igual a zero.

Tabela 2. Correlações de Pearson.

Correlação de Pearson	`education`	`distance`	`score`
`education`	1,000	−0,093	0,465
`distance`	−0,093	1,000	−0,068
`score`	0,465	−0,068	1,000

Tabela 3. Participação e escolaridade média por grupo, sem controles.

Grupo	Categoria	Participação	Escolaridade média (anos)
Renda familiar (`income`)	até US$ 25 mil / acima	71,2% / 28,8%	13,56 / 14,42
Pai graduado (`fcollege`)	não / sim	79,2% / 20,8%	13,55 / 14,80
Mãe graduada (`mcollege`)	não / sim	86,3% / 13,7%	13,65 / 14,82
Escola urbana (`urban`)	não / sim	76,7% / 23,3%	13,82 / 13,76

Essas comparações são brutas, sem controles.

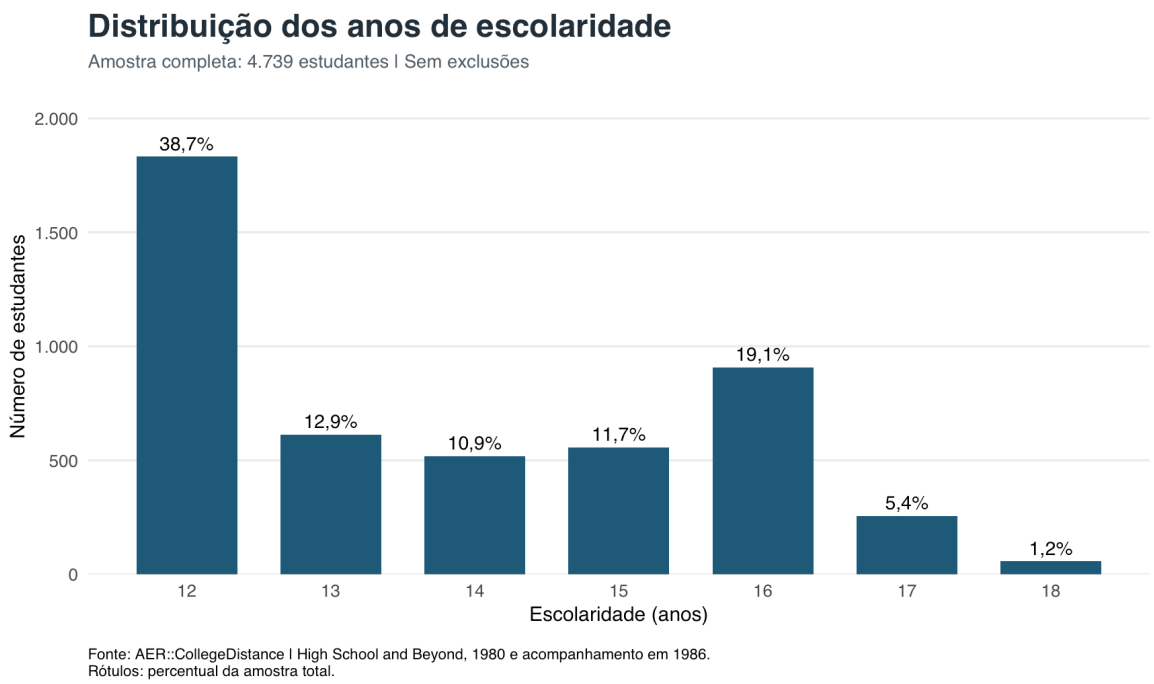


Figura 1. Distribuição da escolaridade.

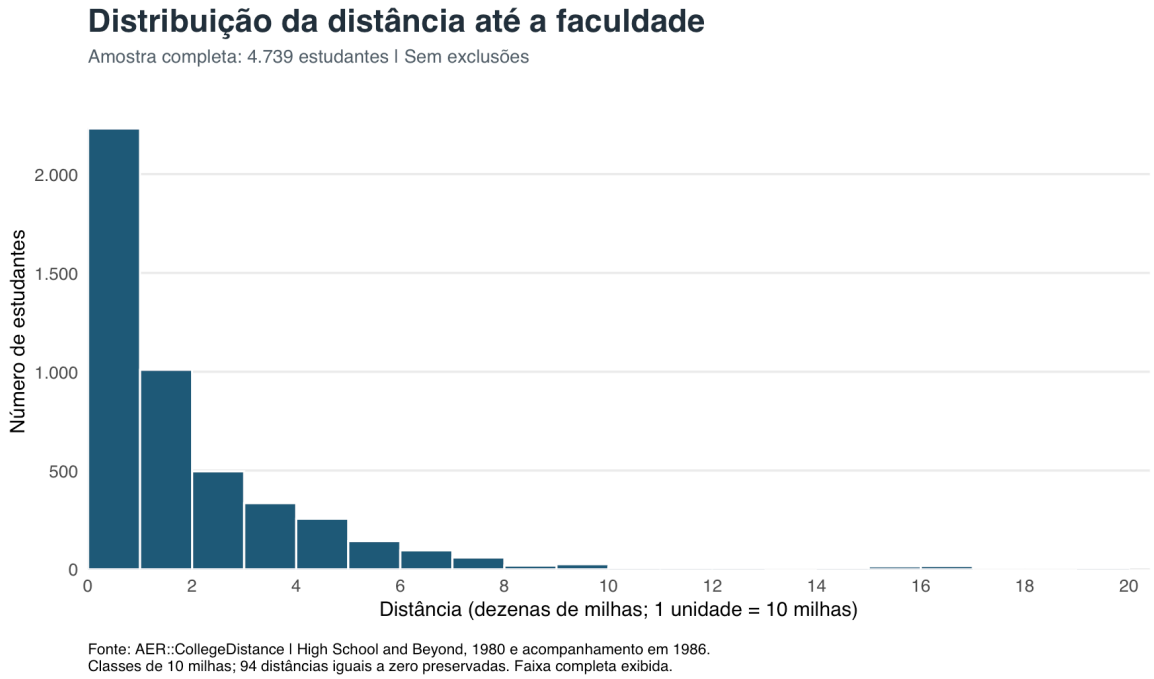


Figura 2. Distribuição da distância até a faculdade.

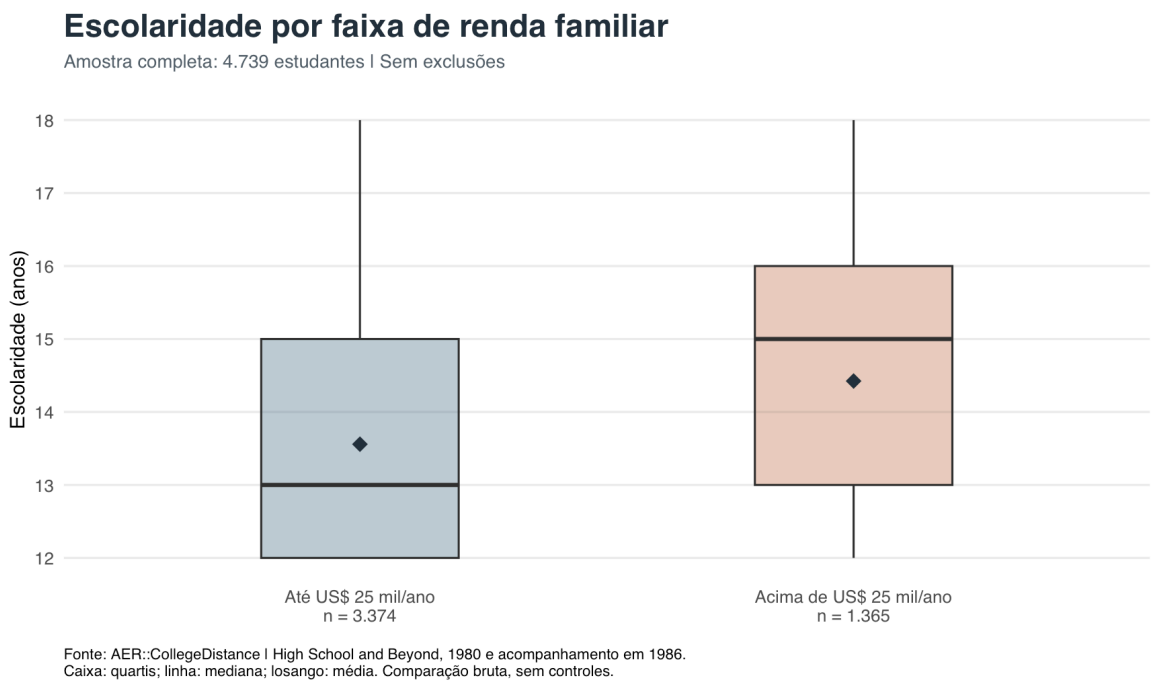


Figura 3. Escolaridade por faixa de renda familiar.

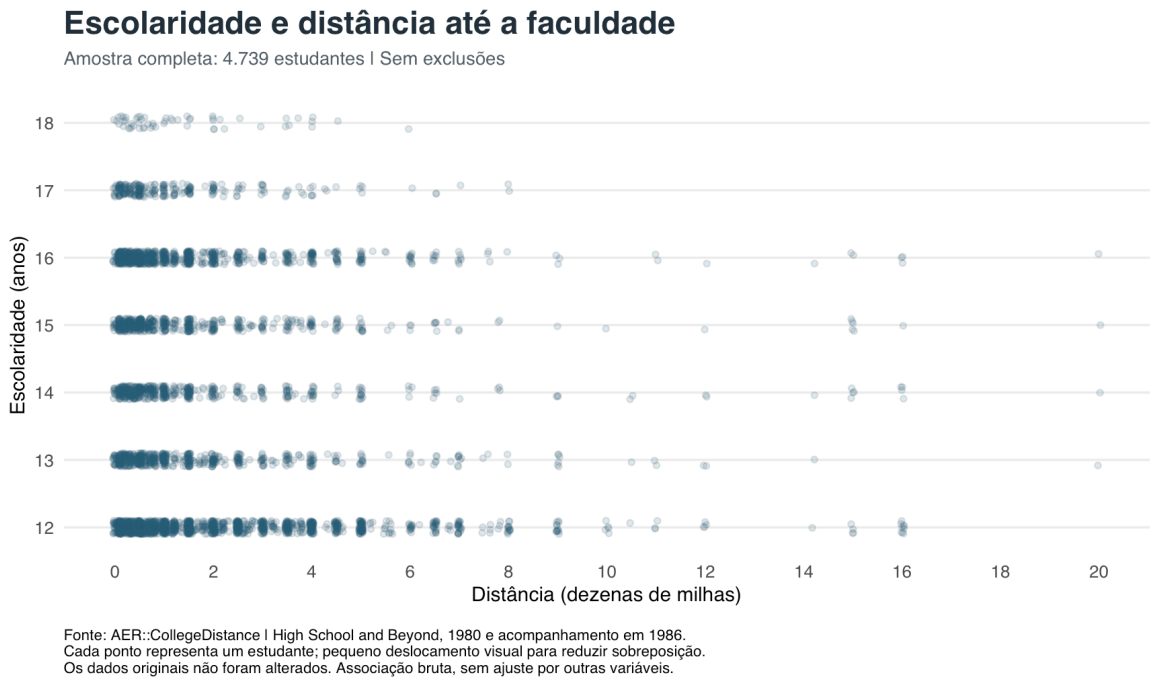


Figura 4. Escolaridade e distância até a faculdade.

3. Variáveis, unidades e categorias de referência

A variável dependente é `education`. Ela é uma escala construída: 12 anos para todos os alunos do último ano do ensino médio, mais anos adicionais e valores atribuídos por diploma, até 18, conforme a construção de Rouse (1995) descrita na documentação do pacote AER.

Tabela 4. Variáveis explicativas, unidades e categorias de referência.

Variável	Significado	Unidade ou categorias	Referência	Entra em
`distance`	Distância até faculdade de quatro anos	1 unidade = 10 milhas	Numérica	Modelos 1, 2 e 3
`income`	Renda familiar anual acima de US$ 25 mil	`low`, `high`	`low`	Modelos 2 e 3
`fcollege`	Pai graduado	`no`, `yes`	`no`	Modelos 2 e 3
`mcollege`	Mãe graduada	`no`, `yes`	`no`	Modelos 2 e 3
`score`	Nota composta nos testes do último ano do ensino médio	Pontos	Numérica	Modelo 3
`gender`	Sexo	`male`, `female`	`male`	Modelo 3
`ethnicity`	Grupo étnico	`other`, `afam`, `hispanic`	`other`	Modelo 3
`urban`	Escola em área urbana	`no`, `yes`	`no`	Modelo 3
`region`	Região	`other`, `west`	`other`	Modelo 3

4. Estimação dos três modelos progressivos

Os modelos foram estimados por Mínimos Quadrados Ordinários (MQO), com a mesma amostra:

$$\text{Modelo 1: } \text{education}_i = \beta_0 + \beta_1 \text{distance}_i + u_i$$

$$\text{Modelo 2: } \text{education}_i = \beta_0 + \beta_1 \text{distance}_i + \beta_2 \text{income}_i + \beta_3 \text{fcollege}_i + \beta_4 \text{mcollege}_i + u_i$$

$$\text{Modelo 3: Modelo 2} + \beta_5 \text{score}_i + \beta_6 \text{gender}_i + \beta_7 \text{afam}_i + \beta_8 \text{hispanic}_i + \beta_9 \text{urban}_i + \beta_{10} \text{west}_i$$

O Modelo 1 mede a associação bruta. O Modelo 2 acrescenta condições familiares, que podem refletir restrição de financiamento, informação e preferências. O Modelo 3 acrescenta desempenho prévio e características demográficas e locais. Essas justificativas são hipóteses econômicas para incluir os controles, não resultados das regressões.

Tabela 5. Modelos progressivos estimados por MQO.

Variável	Modelo 1	Modelo 2	Modelo 3
Intercepto	13,939*** (0,033)	13,495*** (0,037)	8,831*** (0,144)
`distance`	−0,0726*** (0,0110)	−0,0425*** (0,0104)	−0,0238* (0,0096)
`income`: high		0,478*** (0,060)	0,382*** (0,055)
`fcollege`: yes		0,831*** (0,072)	0,548*** (0,066)
`mcollege`: yes		0,571*** (0,080)	0,382*** (0,075)
`score`			0,0896*** (0,0027)
`gender`: female			0,132** (0,045)
`ethnicity`: afam			0,313*** (0,063)
`ethnicity`: hispanic			0,371*** (0,061)
`urban`: yes			0,043 (0,056)
`region`: west			−0,097 (0,057)
Observações	4.739	4.739	4.739
R^2	0,009	0,110	0,269
R^2 ajustado	0,008	0,109	0,268

*Erros padrão HC3 entre parênteses. *** p < 0,001; ** p < 0,01; * p < 0,05.*

O R^2 ajustado é uma medida de ajuste penalizada pelo número de regressores, não um teste de hipótese. A distância sozinha explica menos de 1% da variação da escolaridade.

5. Significância dos coeficientes e intervalos de confiança

Para cada coeficiente, testamos $H_0: \beta_j = 0$ contra $H_1: \beta_j \neq 0$, com

$$t = \frac{\hat{\beta}_j}{EP_{HC3}(\hat{\beta}_j)}, \qquad IC_{95\%} = \hat{\beta}_j \pm t_{0{,}975;\, n-k} \times EP_{HC3}(\hat{\beta}_j)$$

A inferência principal usa erros padrão HC3 (MacKinnon; White, 1985) porque foi encontrada heterocedasticidade (seção 6). O HC3 não muda os coeficientes: ele ajusta o cálculo dos erros padrão para que testes e intervalos não dependam da hipótese de variância constante. A referência é a distribuição t com $n - k$ graus de liberdade.

Tabela 6. Testes t e intervalos de confiança do Modelo 3, com HC3.

Variável	Coeficiente	EP HC3	t	Valor-p	IC 95%
Intercepto	8,8308	0,1442	61,24	< 0,001	[8,5481; 9,1135]
`distance`	−0,0238	0,0096	−2,47	0,013	[−0,0427; −0,0049]
`income`: high	0,3823	0,0552	6,93	< 0,001	[0,2741; 0,4905]
`fcollege`: yes	0,5484	0,0664	8,25	< 0,001	[0,4181; 0,6786]
`mcollege`: yes	0,3821	0,0746	5,12	< 0,001	[0,2359; 0,5283]
`score`	0,0896	0,0027	32,94	< 0,001	[0,0842; 0,0949]
`gender`: female	0,1324	0,0448	2,95	0,003	[0,0445; 0,2202]
`ethnicity`: afam	0,3135	0,0632	4,96	< 0,001	[0,1896; 0,4373]
`ethnicity`: hispanic	0,3705	0,0615	6,02	< 0,001	[0,2499; 0,4911]
`urban`: yes	0,0432	0,0565	0,76	0,444	[−0,0675; 0,1539]
`region`: west	−0,0975	0,0567	−1,72	0,086	[−0,2087; 0,0138]

`urban` e `region` não são estatisticamente distintas de zero a 5%, mas permanecem no modelo: os controles foram definidos por motivo econômico, não por valor-p. Não rejeitar a hipótese nula também não prova que esses coeficientes sejam nulos.

Tabela 7. Coeficiente de `distance` nos três modelos.

Modelo	Coeficiente	EP HC3	IC 95% HC3	p HC3	EP convencional	p convencional
1	−0,0726	0,0110	[−0,0942; −0,0510]	< 0,001	0,0113	< 0,001
2	−0,0425	0,0104	[−0,0629; −0,0221]	< 0,001	0,0108	< 0,001
3	−0,0238	0,0096	[−0,0427; −0,0049]	0,013	0,0103	0,021

As duas últimas colunas são os únicos resultados convencionais desta seção, mostrados para comparação. As conclusões a 5% são as mesmas.

Magnitude: no Modelo 3, 10 milhas a mais se associam a 0,024 ano a menos de escolaridade, cerca de 0,29 mês, com intervalo de 0,06 a 0,51 mês. Entre o primeiro e o terceiro quartis da distância (4 e 25 milhas), a diferença prevista é de 0,050 ano, ou 0,6 mês, o que equivale a 0,028 desvio padrão da escolaridade. O coeficiente é estatisticamente distinto de zero, mas pequeno: significância estatística e relevância econômica são coisas diferentes.

Em módulo, o coeficiente cai 67% do Modelo 1 para o Modelo 3. Como a amostra é a mesma, a queda vem da inclusão dos controles, correlacionados com a distância e com a escolaridade. Os modelos não mostram qual mecanismo está por trás dela.

Mantidas as demais variáveis, estudantes com pai graduado têm, em média, 0,55 ano a mais de escolaridade, e um ponto a mais em `score` se associa a 0,09 ano a mais. Todas essas leituras são associações, não efeitos causais.

6. Diagnósticos selecionados

Tabela 8. Testes RESET e Breusch-Pagan.

Modelo	RESET com HC3: F (p)	RESET clássico: F (p)	Breusch-Pagan studentizado: LM (gl; p)
1	13,39 (< 0,001)	10,66 (< 0,001)	5,13 (1; 0,023)
2	0,59 (0,553)	0,61 (0,544)	5,04 (4; 0,283)
3	8,85 (< 0,001)	6,42 (0,002)	128,66 (10; < 0,001)

Especificação e possível omissão (RESET). O teste (Ramsey, 1969) acrescenta $\hat{y}^2$ e $\hat{y}^3$ ao modelo e verifica se esses termos são conjuntamente nulos. A rejeição no Modelo 3 sugere inadequação da especificação, o que pode envolver forma funcional ou variáveis omitidas. O teste não identifica a variável ausente, não comprova viés e não demonstra exogeneidade. Por isso, a seção 7 compara formas funcionais. A não rejeição no Modelo 2 não prova que ele esteja corretamente especificado.

Heterocedasticidade (Breusch-Pagan). Usamos a versão studentizada (Koenker, 1981) do teste de Breusch e Pagan (1979). A hipótese de variância constante é rejeitada no Modelo 3. Isso não invalida os coeficientes, mas torna inadequados os erros padrão convencionais como referência principal; por isso usamos HC3. No caso de `distance`, a diferença é pequena (0,0103 convencional, 0,0096 HC3). A não rejeição no Modelo 2 não prova homocedasticidade.

Multicolinearidade (VIF e GVIF). Para variáveis com um grau de liberdade, o GVIF (Fox; Monette, 1992) é igual ao VIF. Como `ethnicity` tem dois graus de liberdade, comparamos pelo GVIF ajustado ao quadrado, que fica na escala do VIF.

Tabela 9. VIF e GVIF ajustado ao quadrado no Modelo 3.

Termo (Modelo 3)	VIF ou GVIF ajustado²
`distance`	1,13
`income`	1,19
`fcollege`	1,38
`mcollege`	1,26
`score`	1,23
`gender`	1,01
`ethnicity`	1,14
`urban`	1,15
`region`	1,06

Os valores são próximos de 1, então a multicolinearidade não é uma preocupação relevante aqui, e nenhum controle foi retirado por esse motivo.

Teste de Chow: não aplicado. Ele exige uma hipótese substantiva de diferença entre grupos, e o projeto não definiu nenhuma. Não foram criados cortes arbitrários de distância ou desempenho apenas para realizar o teste.

O que esses procedimentos não comprovam. Exogeneidade e independência entre estudantes não são verificadas por esses testes. Estudantes da mesma escola ou localidade podem ter erros correlacionados, o que HC3 não corrige.

7. Formas funcionais e escolha do modelo

Todas as formas abaixo mantêm os controles do Modelo 3. Salvo indicação em contrário, `score` e as demais explicativas permanecem em nível. A comparação é exploratória e foi motivada pela rejeição do RESET.

Amostra completa (4.739 estudantes)

Tabela 10. Formas funcionais na amostra completa.

Forma	Variáveis transformadas	Coeficientes da distância ou termo adicional (IC 95% HC3)	R^2 ajustado
Linear (Modelo 3)	Nenhuma	`distance`: −0,0238 [−0,0427; −0,0049]	0,2677
Quadrática em `score`	Acrescenta score^2	score^2: 0,00028 [−0,00023; 0,00080]	0,2677
Quadrática em `distance`	Acrescenta distance^2	distance^2: 0,0040 [0,0010; 0,0071]	0,2683
Quadrática nas duas	Acrescenta score^2 e distance^2	distance^2: 0,0041 [0,0010; 0,0072]; score^2: 0,00030 [−0,00021; 0,00082]	0,2684
Log-linear	Só `education` em log	`distance`: −0,0017 [−0,0030; −0,0003]	Não comparável

Os modelos quadráticos usam `distance` e `score` centralizadas nas médias (1,803 e 50,889). O R^2 ajustado do log-linear não é comparável, porque a variável dependente é outra.

Quadrática. Com distance^2, não há uma associação constante ($\hat{y}$ é a escolaridade prevista):

$$\frac{\partial\,\hat{y}}{\partial\,\text{distance}} = \hat{\beta}_1 + 2\hat{\beta}_2\,(\text{distance} - 1{,}803)$$

Nessa especificação, a associação em 10 milhas é de −0,060 ano por 10 milhas (IC 95%: −0,096 a −0,024). O termo quadrático é significativo a 5% (p = 0,010), mas a curva passa a subir depois de cerca de 84 milhas, com apenas 93 estudantes (2,0%) acima desse ponto. Esse trecho crescente tem pouca sustentação nos dados. Para score^2, não há evidência de curvatura (p = 0,284).

Log-linear. Em $\log(\text{education}) = \cdots + \beta\,\text{distance}$, 10 milhas a mais se associam a uma escolaridade cerca de 0,17% menor. Em anos, isso é muito próximo do modelo linear.

Amostra com distância positiva (4.645 estudantes)

Log de zero não existe. Por isso, as formas com log(distance) usam só distâncias positivas: 94 estudantes (2,0%) saem apenas desta comparação. Isso não é limpeza de dados nem solução neutra, pois esses estudantes têm características diferentes (por exemplo, 33% têm pai graduado, contra 21% dos demais). Com a especificação linear, o coeficiente muda pouco com a amostra: de −0,0238 para −0,0244.

Tabela 11. Formas funcionais na amostra com distância positiva.

Forma	Dependente	Distância	Coeficiente da distância (IC 95% HC3)	R^2 ajustado
Linear	`education`	`distance`	−0,0244 [−0,0435; −0,0053]	0,2648
Linear-log	`education`	`log(distance)`	−0,0537 [−0,0934; −0,0139]	0,2651
Log-linear	`log(education)`	`distance`	−0,0017 [−0,0031; −0,0003]	0,2663
Log-log	`log(education)`	`log(distance)`	−0,0039 [−0,0067; −0,0010]	0,2666

O R^2 ajustado só pode ser comparado entre as duas primeiras linhas e entre as duas últimas.

- **Linear-log:** dobrar a distância se associa a $-0{,}0537 \times \ln 2 = -0{,}037$ ano.
- **Log-log:** o coeficiente é uma elasticidade: 1% a mais de distância se associa a uma escolaridade cerca de 0,0039% menor.

Modelo escolhido

Mantemos o **Modelo 3 linear** como especificação principal:

- **Ajuste:** entre modelos comparáveis, o maior ganho de R^2 ajustado é inferior a 0,001 (de 0,2677 para 0,2684). Esse ganho não basta para justificar mais complexidade.
- **Diagnósticos:** o RESET e o Breusch-Pagan continuam rejeitando ($p < 0{,}001$) em todas as formas, então nenhuma alternativa resolve os problemas apontados.
- **Amostra:** o modelo linear preserva todos os estudantes, inclusive os 94 com distância zero.
- **Interpretação:** o coeficiente é lido diretamente em anos por 10 milhas, sem inversão na cauda.

A escolha tem um custo: um único coeficiente pode não descrever igualmente distâncias curtas e longas. Em 10 milhas, a forma quadrática indica −0,060 ano por 10 milhas e a linear-log indica −0,054 (esta sem os zeros), contra −0,024 na linear. Cada estimativa pertence à sua especificação, e esses valores não formam um intervalo de confiança. O sinal negativo em distâncias curtas e típicas se mantém, mas a magnitude depende da forma funcional.

8. Conclusão econômica e limitações

Comparando estudantes com os mesmos controles observados, maior distância até a faculdade se associa a uma escolaridade um pouco menor, mas a magnitude é pequena (0,024 ano por 10 milhas no Modelo 3). A maior parte da associação bruta desaparece quando entram condições familiares e desempenho inicial. Na amostra, renda, educação dos pais e desempenho inicial têm associações mais fortes com a escolaridade do que a distância.

Limitações principais:

- **Causalidade:** o enunciado busca relações de causalidade, mas estas regressões não as demonstram. Controlar por características observadas muda a comparação realizada, sem eliminar a endogeneidade. Escolha do local de moradia, motivação e qualidade da escola podem estar ligadas à distância e à escolaridade.
- **Variável instrumental:** o enunciado lembra que a distância é usada como instrumento em equações de salário. Este trabalho não estima esse modelo e não valida esse uso.

- **Especificação:** o RESET continua rejeitando na especificação escolhida, portanto a forma adotada é uma aproximação.
- **Erros padrão:** HC3 trata a heterocedasticidade, mas não a possível correlação dentro de escolas ou localidades, e a base não identifica a escola. A incerteza pode estar subestimada.
- **Dados:** `education` é discreta e tem mínimo de 12 anos, `income` é apenas uma faixa binária, e os dados descrevem estudantes americanos de 1980 a 1986, sem pesos amostrais.

Reprodução

Os resultados foram produzidos em R pelos scripts `01_descritiva.R`, `02_regressoes.R`, `03_diagnosticos.R` e `04_formas_funcionais.R`, entregues com este trabalho.

Referências

Breusch, T. S.; Pagan, A. R. (1979). A simple test for heteroscedasticity and random coefficient variation. *Econometrica*, 47(5), 1287-1294. DOI: 10.2307/1911963.

Fox, J.; Monette, G. (1992). Generalized collinearity diagnostics. *Journal of the American Statistical Association*, 87(417), 178-183. DOI: 10.1080/01621459.1992.10475190.

Kleiber, C.; Zeileis, A. (2008). *Applied Econometrics with R*. New York: Springer-Verlag. DOI: 10.1007/978-0-387-77318-6.

Koenker, R. (1981). A note on studentizing a test for heteroscedasticity. *Journal of Econometrics*, 17(1), 107-112. DOI: 10.1016/0304-4076(81)90062-2.

MacKinnon, J. G.; White, H. (1985). Some heteroskedasticity-consistent covariance matrix estimators with improved finite sample properties. *Journal of Econometrics*, 29(3), 305-325. DOI: 10.1016/0304-4076(85)90158-7.

Ramsey, J. B. (1969). Tests for specification errors in classical linear least-squares regression analysis. *Journal of the Royal Statistical Society: Series B*, 31(2), 350-371. DOI: 10.1111/j.2517-6161.1969.tb00796.x.

Rouse, C. E. (1995). Democratization or diversion? The effect of community colleges on educational attainment. *Journal of Business & Economic Statistics*, 13(2), 217-224. DOI: 10.1080/07350015.1995.10524596.

Stock, J. H.; Watson, M. W. (2007). *Introduction to Econometrics*. 2. ed. Boston: Pearson/Addison Wesley.